VNUHCM-UNIVERSITY OF SCIENCE

FACULTY OF INFORMATION TECHNOLOGY

KHAI THÁC DỮ LIỆU VÀ ỨNG DỤNG

LAB ASSIGNMENT 01:

DATA PREPROCESSING

DATA MINING AND ITS APPLICATIONS

NHÓM THỰC HIỆN

NHÓM 4

GIÁO VIÊN HƯỚNG DẪN:

THẦY: LÊ HOÀI BẮC

THẦY: NGUYỄN NGỌC ĐỨC

THẦY: LÊ NHỰT NAM

TÓM TẮT ĐỒ ÁN

- Đồ án này tập trung vào bước tiền xử lý dữ liệu trong quy trình Data Mining, nhằm chuẩn bị dữ liệu cho các mô hình học máy. Nhóm thực hiện tiền xử lý trên ba loại dữ liệu khác nhau: dữ liệu ảnh, dữ liệu bảng và dữ liệu văn bản.
- Đối với dữ liệu ảnh, các kỹ thuật như resize, chuyển grayscale, normalization và standardization được áp dụng nhằm chuẩn hóa kích thước và phân phối giá trị pixel. Với dữ liệu bảng, nhóm xử lý giá trị thiếu, chuẩn hóa dữ liệu, mã hóa biến phân loại và lựa chọn đặc trưng phù hợp. Đối với dữ liệu văn bản, các bước làm sạch, tokenization, loại bỏ stop words, stemming, lemmatization và vector hóa bằng Bag of Words và TF-IDF được thực hiện.
- Kết quả cho thấy tiền xử lý đóng vai trò quan trọng trong việc nâng cao chất lượng dữ liệu và ảnh hưởng trực tiếp đến hiệu quả của mô hình học máy.

I. GIỚI THIỆU NHÓM

Nhóm 4 bao gồm 3 thành viên:

Mã số sinh viên	Họ tên
20127119	Phạm Nguyễn Gia Bảo
20127157	Lê Nguyễn Chí Hiếu
21127498	Trần Quang Đạo

II. GIỚI THIỆU BÀI TOÁN

Trong các hệ thống Data Mining và Machine Learning, chất lượng dữ liệu đầu vào đóng vai trò quyết định đến hiệu suất và độ chính xác của mô hình. Dữ liệu thực tế thường tồn tại dưới nhiều dạng khác nhau như hình ảnh, bảng số liệu và văn bản. Mỗi loại dữ liệu có đặc điểm riêng và đòi hỏi các kỹ thuật tiền xử lý phù hợp.

Mục tiêu của đồ án là:

- Áp dụng các kỹ thuật tiền xử lý cho nhiều loại dữ liệu khác nhau
- Phân tích tác động của từng kỹ thuật
- So sánh và đánh giá hiệu quả trước – sau khi tiền xử lý

Nhóm thực hiện tiền xử lý trên:

- Image Data
- Tabular Data
- Text Data (Bonus)

III. IMAGE DATA PREPROCESSING

a. Dataset Description

Dataset ảnh được sử dụng gồm các hình ảnh phục vụ cho bài toán phân loại. Ảnh có kích thước không đồng nhất và giá trị pixel trong khoảng [0,255].

Các vấn đề chính của dữ liệu ảnh:

- Kích thước khác nhau
- Phân phối pixel chưa chuẩn hóa
- Số chiều dữ liệu lớn (3 kênh màu)

Nguồn và link tải:
https://drive.google.com/file/d/1rJ25_o8uRaKpVJrWKZwGWpnotGyMVidG/view?usp=sharing

- **Đặc điểm:** Bao gồm các hình ảnh có độ phân giải và tỷ lệ khung hình khác nhau, đa dạng về bối cảnh và điều kiện ánh sáng.
- **Mục đích sử dụng:** Phân loại vật thể / chẩn đoán hình ảnh.

b. Resize

Ảnh được resize về kích thước thống nhất

Lý do:

Các mô hình Deep Learning (như CNN) yêu cầu đầu vào phải có kích thước ma trận cố định. Việc thay đổi kích thước ảnh (Resizing) giúp đồng nhất tensor đầu vào, tuy nhiên cần cẩn trọng để không làm méo mó các đặc trưng quan trọng.

- Mô hình CNN yêu cầu đầu vào có kích thước cố định
- Giảm chi phí tính toán
- Tăng khả năng batch training

Trade-off:

- Ảnh nhỏ hơn → tính toán nhanh hơn
- Nhưng có thể mất chi tiết hình ảnh

Chi tiết cài đặt (Implementation Details): Đọc ảnh bằng thư viện OpenCV/PIL, sau đó sử dụng thuật toán nội suy (interpolation) để scale toàn bộ ảnh về chung kích thước

Phân tích kết quả (Results & Analysis): Việc chọn kích thước nhỏ giúp giảm thiểu chi phí tính toán và yêu cầu bộ nhớ, nhưng đánh đổi lại là mất đi độ sắc nét của các chi tiết nhỏ. Thuật toán nội suy phù hợp giúp ảnh không bị rạn hạt quá mức khi thay đổi tỷ lệ khung hình.

c. Grayscale Conversion

Ảnh màu được chuyển sang grayscale trong một số thử nghiệm.

Lý do: Đối với các bài toán mà màu sắc không đóng vai trò quyết định (như nhận diện khuôn mặt, dò biên vật thể), việc chuyển từ hệ màu RGB (3 kênh) sang Grayscale (1 kênh) giúp giảm 2/3 khối lượng dữ liệu tính toán.

Hạn chế:

- Mất thông tin màu sắc
- Có thể ảnh hưởng tới độ chính xác nếu màu là đặc trưng quan trọng

Chi tiết cài đặt: Tính toán giá trị cường độ sáng pixel dựa trên công thức có trọng số của 3 kênh R, G, B để phản ánh đúng mức độ cảm nhận ánh sáng của mắt người.

Phân tích kết quả: Cấu trúc, hình khối và độ tương phản của vật thể vẫn được giữ nguyên vẹn trên ảnh xám. Điều này chứng minh rằng việc lược bỏ thông tin màu sắc là có lợi cho việc tối ưu hiệu suất mô hình mà không làm giảm khả năng nhận diện hình thái vật thể.

d. Normalization & Standardization

Normalization: Pixel được scale về [0,1].

Standardization: Dữ liệu được chuẩn hóa về mean ≈ 0 và std ≈ 1

Lý do: Pixel ban đầu có giá trị từ 0 đến 255. Dải giá trị rộng này có thể làm cho quá trình huấn luyện mô hình học sâu bị chậm (gradient descent mất nhiều thời gian hội tụ).

Tác dụng:

- Ổn định gradient
- Tăng tốc hội tụ
- Giảm chênh lệch giá trị lớn

Chi tiết cài đặt:

Normalization: Chia giá trị pixel cho 255 để đưa về dải [0, 1].

Standardization: Trừ đi giá trị trung bình (mean) và chia cho độ lệch chuẩn (std) của toàn bộ tập dữ liệu để phân phối có zero-mean và unit-variance.

Phân tích kết quả: Sau khi thực hiện, biểu đồ Histogram của ảnh phân bố tập trung hơn. Standardization đặc biệt hiệu quả trong việc xử lý các ảnh có độ sáng tối không đồng đều, giúp mạng nơ-ron học các đặc trưng về cạnh/góc dễ dàng hơn là bị nhiễu bởi cường độ sáng tổng thể.

e. Edge Detection (Bonus - Thuật toán Canny)

Lý do: Tìm kiếm các đường bao, góc cạnh sắc nét để trích xuất đặc trưng hình học (shape features) mang tính đại diện cao.

Chi tiết cài đặt: Sử dụng thuật toán Canny.

Phân tích kết quả: Kết quả trực quan hóa cho thấy thuật toán Canny tách cực tốt vật thể ra khỏi nền (background subtraction). Các đường biên tìm được là các điểm có cường độ sáng thay đổi đột ngột. Điều này cực kỳ có ý nghĩa vì nó giúp mô hình học máy sau này chỉ tập trung vào "bộ xương" cấu trúc của vật thể thay vì bị phân tâm bởi yếu tố nền, ánh sáng hay màu sắc nhiễu.

f. Kết luận phần Image

Sau tiền xử lý:

- Ảnh được chuẩn hóa kích thước
- Giá trị pixel được scale và chuẩn hóa
- Dữ liệu sẵn sàng cho các mô hình Deep Learning

IV. TABULAR DATA PREPROCESSING

1. Mô tả tập dữ liệu

- **Tên dataset:** Credit Card Fraud Detection (Nguồn: https://drive.google.com/file/d/1birhslq88-6l_L-A3I4eQA2Ht4ApbYnp/view?usp=sharing).
- **Kích thước & Mô tả:** Gồm 284,807 dòng giao dịch thẻ tín dụng trong 2 ngày, với 30 thuộc tính (Features). Từ biến V1 đến V28 là các thông tin đã được ẩn danh hóa bằng thuật toán PCA. Hai cột chưa ẩn danh là Time và Amount.
- **Đặc điểm bài toán:** Dữ liệu mất cân bằng nghiêm trọng khi chỉ có 492 giao dịch gian lận (0.17%). Do bộ dữ liệu gốc đã quá hoàn hảo, nhóm đã tiến hành tạo các tình huống giả lập (missing data, categorizing biến liên tục) để áp dụng các kỹ thuật.

2. Xử lý giá trị thiếu (Handling Missing Values)

- **Lý do thực hiện:** Giả định tình huống lỗi hệ thống (MCAR - Missing Completely At Random), nhóm chủ động tạo ra lượng khuyết thiếu ngẫu nhiên tại cột Amount. Việc để trống dữ liệu sẽ khiến các mô hình không thể hoạt động.
- **Chi tiết cài đặt:** Áp dụng hai chiến lược để đối chiếu: *Mean Imputation* (Điền trung bình) và *Median Imputation* (Điền trung vị).
- **Phân tích kết quả:** Cột Amount (số tiền) bị lệch phải rất mạnh do chứa các giao dịch ngoại lai có giá trị cực lớn (Outliers lên tới hàng nghìn đô la). Do đó, khi

dùng trung bình (Mean), giá trị điền khuyết bị kéo lên cao, làm sai lệch phân phối ban đầu của các giao dịch nhỏ. Nhóm ưu tiên sử dụng Trung vị (Median) để điền khuyết vì nó không bị ảnh hưởng bởi các giá trị ngoại lai, giữ nguyên được đặc điểm phân phối cốt lõi của dữ liệu tài chính.

3. Chuẩn hóa dữ liệu (Data Scaling)

- **Lý do thực hiện:** Các cột từ V1-V28 đã được scale quanh mức 0, nhưng cột Amount dao động từ 0 đến khoảng 25,000$. Sự chênh lệch biên độ này sẽ làm cho các thuật toán tính toán khoảng cách (như KNN, SVM) bị chệch, đánh giá quá mức tầm quan trọng của cột Amount.
- **Chi tiết cài đặt:** Thử nghiệm *Min-Max Scaler*, *StandardScaler* và *RobustScaler*.
- **Phân tích kết quả:**
    - Min-Max ép phân phối lại nhưng làm các giao dịch nhỏ bẹp dúm gần mốc 0 do ảnh hưởng của max outlier.
    - Nhóm quyết định sử dụng RobustScaler vì thuật toán này sử dụng dải tứ phân vị (IQR), giúp scale dữ liệu hiệu quả bằng cách phớt lờ hoàn toàn sự ảnh hưởng của các Outliers khổng lồ, giữ lại hình dáng phân bố tốt nhất cho mô hình học máy.

4. Mã hóa biến phân loại (Categorical Encoding)

- **Lý do thực hiện:** Biến Time (số giây từ giao dịch đầu) khó cung cấp quy luật trực tiếp. Nhóm dùng Feature Engineering để biến (binning) cột này thành các khoảng thời gian mang tính định danh phân loại: Sáng, Trưa, Chiều, Tối để khai thác thói quen gian lận.
- **Chi tiết cài đặt:** Do các buổi trong ngày không mang tính chất thứ bậc độ lớn rõ ràng, việc gán số 1, 2, 3, 4 (Ordinal) có thể gây nhầm lẫn cho model. Nhóm quyết định dùng One-Hot Encoding để chẻ ra thành các cột nhị phân độc lập.
- **Phân tích kết quả:** Phương pháp này tăng số chiều dữ liệu nhẹ nhưng mô tả chính xác đặc tính của dữ liệu, giúp model sau này dễ dàng thiết lập luật (rule) nhận diện thời điểm rủi ro xảy ra gian lận cao nhất.

5. Chọn lọc đặc trưng (Feature Selection)

- **Lý do thực hiện:** Dữ liệu có 30 cột gốc và sinh thêm nhiều cột từ One-hot Encoding. Giữ lại các đặc trưng mang tính "nhiễu" sẽ làm mô hình học vẹt (Overfitting) và chạy chậm.
- **Chi tiết cài đặt:** Nhóm kết hợp đánh giá từ 2 góc độ: tương quan tuyến tính (Ma trận Correlation Pearson) và tương quan phi tuyến (Feature Importance của thuật toán Random Forest).

- **Phân tích kết quả:** * Cả biểu đồ Heatmap và Random Forest đều đánh giá cao nhất vai trò của bộ 3 biến: V17, V14, V12. Đây là các biến có tương quan nghịch mạnh với nhãn Class (giá trị càng nhỏ, rủi ro gian lận càng cao).
    - Các biến từ thời gian và một số biến PCA ở đuôi (V22, V23...) đóng góp không đáng kể. Dựa trên kết quả này, nhóm tiến hành lược bỏ (Drop) và chỉ giữ lại Top 15 đặc trưng quan trọng nhất để tạo ra bộ dataframe hoàn chỉnh cuối cùng.

V. TEXT DATA PREPROCESSING

a. Dataset Description

Dataset IMDB gồm 50,000 review với nhãn positive/negative.

Link: https://drive.google.com/file/d/1NDFNPsFLPmXVPkIYLtcORUcOAqerLPPP/view?usp=sharing

Đặc điểm:

- Văn bản không cấu trúc
- Độ dài không đồng đều
- Chứa HTML và ký tự đặc biệt

b. Text Cleaning

Thực hiện:

- Lowercase
- Loại bỏ HTML
- Loại ký tự đặc biệt
- Chuẩn hóa khoảng trắng

Giúp chuẩn hóa dữ liệu trước khi phân tích.

c. Tokenization

Chia văn bản thành danh sách token để xử lý.

Sau bước này, dữ liệu chuyển sang dạng có thể xử lý bằng toán học.

d. Removing Stop Words

Số token giảm từ 313 xuống 162 (~48%).

Loại bỏ stop words giúp:

- Giảm kích thước từ vựng

- Tăng mật độ thông tin
- Cải thiện chất lượng vector hóa

e. Stemming và Lemmatization

So sánh hai phương pháp:

Tiêu chí	Stemming	Lemmatization
Tốc độ	Nhanh	Chậm hơn
Độ chính xác	Thấp	Cao
Giữ nghĩa	Không hoàn toàn	Tốt

Lemmatization phù hợp hơn cho sentiment analysis vì giữ được ngữ nghĩa.

f. Vectorization

Bag of Words

- Tạo ma trận (50000, 5000)
- Giá trị là số lần xuất hiện của từ

TF-IDF

- Cũng tạo ma trận (50000, 5000)
- Giá trị là trọng số

TF-IDF hiệu quả hơn vì giảm ảnh hưởng của từ phổ biến.

g. Kết luận phần Text

Tiền xử lý giúp:

Giảm nhiễu

- Chuẩn hóa dữ liệu
- Chuyển văn bản sang dạng vector số
- Chuẩn bị cho mô hình NLP

VI. PHÂN CHIA CÔNG VIỆC

Thành viên	Phụ trách	Nhiệm vụ
Phạm Nguyễn Gia Bảo	Image	Resize, Grayscale, Normalization, Standardization
Trần Quang Đạo	Tabular	Missing values, Scaling, Encoding, Feature selection
Lê Nguyễn Chí Hiếu	Text + Report	Text preprocessing, Vectorization, Tổng hợp báo cáo

VII. ĐÁNH GIÁ TỔNG THỂ

Qua quá trình thực hiện, có thể rút ra:

- Mỗi loại dữ liệu cần kỹ thuật xử lý riêng
- Không tồn tại một phương pháp chung cho mọi loại dữ liệu
- Tiền xử lý ảnh hưởng trực tiếp đến chất lượng mô hình

VIII. KẾT LUẬN CHUNG

Đồ án đã thực hiện đầy đủ các bước tiền xử lý cho ba loại dữ liệu khác nhau và phân tích tác động của từng kỹ thuật.

Kết quả cho thấy tiền xử lý là bước quan trọng và bắt buộc trong quy trình Data Mining.

HẾT